

Algoritmos Genéticos para o Problema do Caixeiro Viajante: Uma Análise Comparativa de Operadores Genéticos

Este artigo apresenta uma análise detalhada da aplicação de Algoritmos Genéticos (AGs) na resolução do Problema do Caixeiro Viajante (TSP). Investigamos o impacto de diferentes operadores genéticos, incluindo métodos de crossover, taxas de mutação, estratégias de inicialização da população e critérios de parada. Nossos experimentos utilizam nove conjuntos de dados com diferentes complexidades, variando de 5 a 30 cidades. Os resultados demonstram que a combinação de crossover de ordem com mutação por inversão e inicialização baseada no vizinho mais próximo produz soluções de alta qualidade com tempo computacional razoável.

Palavras-chave: Algoritmos Genéticos, Problema do Caixeiro Viajante, Otimização Combinatória, Operadores Genéticos

Introdução:

O Problema do Caixeiro Viajante (TSP) é um dos problemas de otimização combinatória mais estudados em ciência da computação. O objetivo é encontrar o caminho mais curto que visita cada cidade exatamente uma vez e retorna à cidade de origem.

Algoritmos Genéticos (AGs) são metaheurísticas inspiradas na evolução natural que se mostraram eficazes para resolver problemas complexos de otimização como o TSP. Este trabalho implementa e compara diferentes configurações de AGs para resolver instâncias do TSP, analisando o impacto de variações nos operadores genéticos.

Metodologia

Implementação do Algoritmo Genético:

Implementamos um AG com as seguintes características:

- **Representação:** Permutação de cidades (tour)
- **Função de Fitness:** Distância total do tour (a ser minimizada)
- **Seleção:** Torneio (tamanho 5)
- **Crossover:** PMX, OX e CX
- **Mutação:** Inversão de sub-rota
- **Elitismo:** Preserva os melhores indivíduos entre gerações
- **Critério de Parada:** 500 gerações ou 50 gerações sem melhoria

Parâmetros Analisados:

1. Operadores de Crossover:

- PMX (Partially Mapped Crossover)
- OX (Ordered Crossover)
- CX (Cycle Crossover)

2. Taxas de Mutação:

- Baixa (0.001)
- Média (0.01)
- Alta (0.1)

3. Inicialização da População:

- Aleatória
- Heurística (Vizinho Mais Próximo)

Conjuntos de Dados

Foram utilizadas 10 instâncias do TSP com tamanhos variando de 5 a 30 cidades. Os experimentos foram realizados com 5 execuções independentes para cada configuração.

Resultados

Comparação de Operadores de Crossover

Crossover	Distância Média	Tempo Médio (s)
PMX	512.34	8.76
OX	528.91	9.12
CX	539.22	9.45

O PMX demonstrou superioridade em qualidade de solução e tempo de execução para a maioria das instâncias.

Efeito da Taxa de Mutação

Taxa Mutação	Distância Média	Convergência
0.001	541.28	Lenta
0.01	512.34	Equilibrada
0.1	529.47	Rápida

Taxas muito baixas (0.001) resultaram em convergência prematura, enquanto taxas altas (0.1) prejudicaram a qualidade das soluções.

Inicialização da População

Método	Distância Média	Tempo (s)
-----	-----	-----
Aleatória	512.34	8.76
Vizinho Próximo	489.57	6.82

A inicialização heurística melhorou a qualidade das soluções em 4.5% e reduziu o tempo de execução em 22%.

Discussão:

Os resultados demonstram que:

1. O operador PMX foi mais eficaz para o TSP
2. Taxas de mutação médias (0.01) produziram o melhor equilíbrio
3. A inicialização heurística melhorou significativamente o desempenho
4. O critério de parada antecipada reduziu o tempo sem prejudicar a qualidade

Conclusão

A melhor configuração encontrada foi:

- Crossover: PMX
- Mutação: 0.01
- Inicialização: Heurística (Vizinho Mais Próximo)
- Critério de Parada: 50 gerações sem melhoria